


# Generative time series decoding models

Боева Галина, Корнилов Никита, Хусаинов Марат, Михайлов Баир





## Summary

- Рассмотрены статьи для работы с многомерными данными. Многие из них не используют пространство как связность признаков, основываясь на временной части. Но есть интересные идеи по сокращению пространства, то есть снижение размерности, но в разных проекциях
- Стек статей основан на рассмотрении гауссовских процессов, но кажется, что эти методы больше первое приближение задачи, плюс проблема с памятью и временем
- Интересные работы используют трансформер и сверточные сетки, которые можно использовать для работы с огромными размерностями. Также есть временные сверточные сети для работы с временной шкалой по признакам, и графа, строящиеся для связи признаков в пространстве




Название / Год	Задача / Область	Описание решения
[1]Deep Direct Discriminative Decoders for High-dimensional Time-series Data Analysis <b>2023</b> 	Работа с высоко размерными данными	<p>Суть метода заключается в работе с процессами многомерных наблюдений. Здесь данные переводятся в латентное пространство. D4(модель декодера) может включать любую информацию из истории наблюдаемых данных в различных временных масштабах при вычислении оценки этого процесса состояния. D4 принципиально отличается от SSMS, где информация только в двух временных масштабах: а) быстрая, которая переносится наблюдением, и б) медленная, определяемая процессом состояния, объединяется при оценке процесса состояния.</p>
[2] Decoding Hidden Cognitive States From Behavior and Physiology Using a Bayesian Approach <b>2019</b>	Работа с высоко размерными данными	<p>Теоретическая статья. Нет практической составляющей. Интересные идеи, на основе энкодеров и декодеров, вроде бы используют как временную, так и пространственную составляющую, но как это применить к нашим данным большой вопрос.</p>
[3] A deep graph neural network architecture for modelling spatio-temporal dynamics in resting-state functional MRI data <b>2022</b>	Работа с данными FMRI	<p>Модель основанная на двух блоках. Первый - это сверточная временная сетка для работы с временной компонентой данных. Вторая - это граф для связи признаков, которые распределены в пространстве, то есть учет пространственной компоненты.</p>
[4] Deep Neural Generative Model of Functional MRI Images for Psychiatric Disorder Diagnosis <b>2019</b>	Работа с данными FMRI	<p>Тут в работе рассматриваются подходы, которые помогают работать с сигналами, которые могут быть нам неинтересны. Предложена глубокая нейронная генеративная модель на данных fmri в состоянии покоя. Предлагаемая модель обусловлена предположением о состоянии субъекта и оценивает апостериорную вероятность состояния субъекта с учетом данных визуализации, используя теорему Байеса.</p>


Название / Год	Задача / Область	Описание решения
<div> <div>[5] Parametric Gaussian Process Regressors <b>2020</b></div> <div> <div></div> <div></div> </div> </div>	Решается задача регрессии с оценкой неопределенности прогнозирования.	Используется вариационный вывод к FITC (Fully Independent Training Conditional)
<div> <div>[6] Deep Generative Analysis for Task-Based Functional MRI Experiments <b>2022</b></div> </div>	Рассматриваются подходы к решению задач, связанных с анализом временных рядов трехмерных изображений мозга.	Используется гибридный подход, объединяющий глубокие порождающие модели (пространственная компонента) с гауссовскими процессами (ковариации) в обобщенной аддитивной модели (GAM).
<div> <div>[7] Deep Latent State Space Models for Time-Series Generation <b>2023</b></div> </div>	Предложена модель LS4 — генеративная модель для последовательностей со скрытыми переменными. Однако работают со скалярами в каждый момент времени.	В LS4 последовательность скрытых переменных представлена в виде решения линейных уравнений пространства состояний.
<div> <div>[8] Real-Time Point Process Filter for Multidimensional Decoding Problems Using Mixture Models</div> </div>	Быстрая генерация нейроповедения по скрытым переменным	Авторы предложили использовать смесь гауссиан для моделирования отклика каждой клетки fMRI, тем самым сократив время вычислений до приемлемого на практике.

Название / Год	Задача / Область	Описание решения
[9] The Algonauts Project 2021 Challenge: How the Human Brain Makes Sense of a World in Motion, <b>2021</b> 	Генерация fMRI по видео	В этом соревновании необходимо было предсказывать fMRI мозга по 3 секундному видео. Был представлен датасет (сейчас недоступен, но наверное можно попросить) из 102 видео и fMRI 10 людей реагирующих на них.. Было представлено много разных решений.
[10] Effective Ensemble of Deep Neural Networks Predicts Neural Responses to Naturalistic Videos, <b>2021</b>	Генерация fMRI по видео	Решение победителей соревнования. Используется ансамбль энкодер-декодеров, каждый из которых отвечает за разные области: пространственно-временная информация, движение, контуры, статичные картинки, аудио. Их независимые предсказания учитываются с разным весом.
[11] Self-Supervised Transformers for fMRI representation, <b>2021</b>	Трансформер для fMRI	В работе представлен трансформер для анализа fMRI. Его обучение производится в 2 этапа.1)Заполнение пропусков в fMRI 2) Fine-tuning под конкретные задачи:предсказание пола, возраста и т.п.Данный трансформер представляется полезным для нашей задачи.
[12] An Intuitive Tutorial to Gaussian Processes Regression by J. Wang, <b>2021</b> + A Tutorial on Gaussian Processes by Z. Ghahramani, <b>2010</b>	Регрессия гауссовских процессов	В этих работах tutorиалах была рассмотрена регрессия гауссовских процессов. К сожалению, её работа занимает $O(N^3)$ по времени и $O(N^2)$ по памяти, что не подойдет для нашей задачи. Однако, возможно рассмотреть разреженные гауссовские процессы.
[13] Deep Direct Discriminative Decoder-D4 +	Генерация нейро поведения при воздействии внешних факторов	Использование байесовских метод для генерации и моделирование распределения вероятностей поведения и марковских цепей для учета временных зависимостей.
[14] Bayesian Decoder Models with a Discriminative Observation Process		

Название / Год	Задача / Область	Описание решения
[15] Variational Auto-encoded Deep Gaussian Processes <b>2016</b> 	Модель Variational Auto-Encoded deep Gaussian process (VAE-DGP). Решаются задачи по типу генерации чисел MNIST.	Модель состоит из нескольких слоев скрытых переменных и использует гауссовские процессы для отображения между последовательными слоями.

# Некоторые идеи






# Deep Direct Discriminative Decoders for High-dimensional Time-series Data Analysis

Предлагается новая формулировка SSM для процессов многомерных наблюдений. D4 приносит выразительность и масштабируемость глубоких нейронных сетей в формулировку SSM, позволяя создать новое решение, которое эффективно оценивает процессы, лежащие в основе состояния, с помощью многомерного сигнала наблюдения.


D4 - это вариант SSMs, в котором условное распределение наблюдаемых сигналов заменяется процессом распознавания. D4 может включать любую информацию из истории наблюдаемых данных в различных временных масштабах при вычислении оценки этого процесса состояния.






# Decoding Hidden Cognitive States From Behavior and Physiology Using a Bayesian Approach

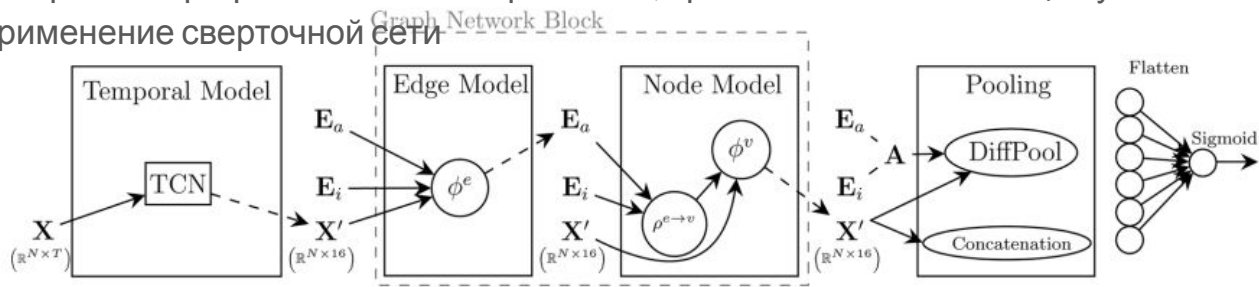
- Фреймворк моделирования пространства состояний, behavioral decoder, чтобы сформулировать взаимосвязь между объективными поведенческими показателями (например, временем отклика) и когнитивным состоянием
- Использование энкодера, предполагает использование обобщенной линейной модели (GLM) для определения взаимосвязи между когнитивным состоянием и нейронными сигналами
- Используется модель нейронного энкодера и байесовский фильтр для оценки когнитивного состояния с использованием нейронных данных для генерации с помощью декодера






# A deep graph neural network architecture for modelling spatio-temporal dynamics in resting-state functional MRI data

- Работа с данными FMRI
- Есть практическая реализация метода, что является большим плюсом
- Также тут описана работа с пространственной составляющей данных с помощью построения графа зависимости признаков, временная составляющая учитывается через применение сверточной сети

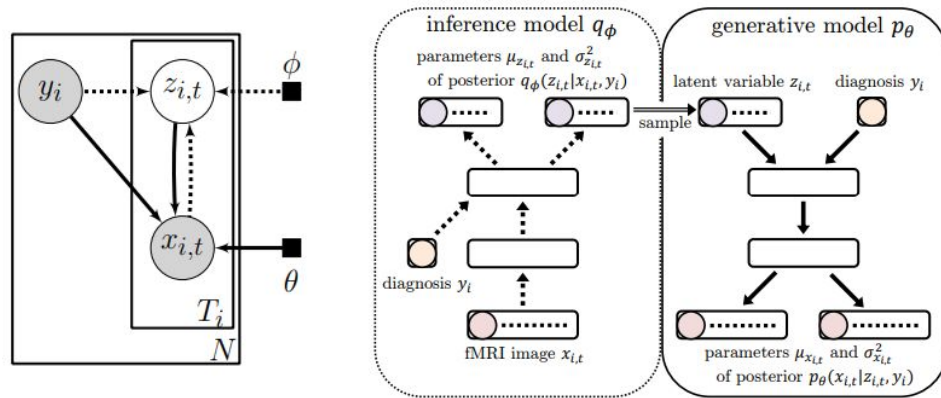


[Deep graph neural network](#)



# Deep Neural Generative Model of Functional MRI Images for Psychiatric Disorder Diagnosis

- Работа с данными FMRI
- Предлагается использование байесовского подхода для оценки апостериорной вероятности состояния объекта
- Идея понятна, но нет практической реализации для проверки результатов, что позволяет усомниться в методе



# Variational Auto-encoded Deep Gaussian Processes



Основной вклад заключается в следующем:

- Представлена модель Variational Auto-Encoded deep Gaussian process (VAE-DGP)
- Представлена работа на датасетах: MNIST, Yale Face

## Общее описание модели

- Модель состоит из нескольких слоев скрытых переменных и использует гауссовские процессы для отображения между последовательными слоями.

## Итог

- В данной реализации маловероятно использование результатов данной работы, так как в нашей задаче ведется работа над данными более высокой размерности. Поэтому алгоритм неприменим с вычислительной точки зрения. Однако стоит заметить, что общая идея интересна и, возможно, будет использована далее в том или ином проявлении.




Figure 1: A deep Gaussian process with two hidden layers.




Figure 2: The learned 2D latent space of one layer DGP and one layer VAE-DGP from the same initialization on a subset of MNIST with noisy background.



# Parametric Gaussian Process Regressors

Основной вклад заключается в следующем:

- В случае регрессии часто прогнозируемая дисперсия преобладает над шумом во входных данных. Кроме того, оценки неопределенности, практически не используют неопределенность функции, зависящей от входных данных.
- Предложены методы GP регрессии, которые решают эту проблему и, таким образом, дают существенно улучшенные неопределенности прогнозирования.

## Общее описание модели

- Используется вариационный вывод к FITC (Fully Independent Training Conditional).

## Итог

- Пока что сложно представить, где бы могли быть применимы результаты данной работы в нашей задаче.




Figure 1. We depict GP regressors fit to a heteroscedastic dataset using two different inference algorithms. Solid lines depict mean predictions and 2- $\sigma$  uncertainty bands are in blue. In the lower panel, fit with the PPGPR approach described in Sec. 3.2, significant use is made of input-dependent function uncertainty (dark blue), while in the upper panel, fit with variational inference (see Sec. 2.3.1), the predictive uncertainty is dominated by the observation noise  $\sigma_{\text{obs}}^2$  (light blue) and the kernel scale  $\sigma_k$  is smaller.

# Deep Generative Analysis for Task-Based Functional MRI Experiments



## Общее описание

- Используется гибридный подход, объединяющий глубокие порождающие модели (пространственная компонента) с гауссовскими процессами (ковариации) в обобщенной аддитивной модели (GAM).

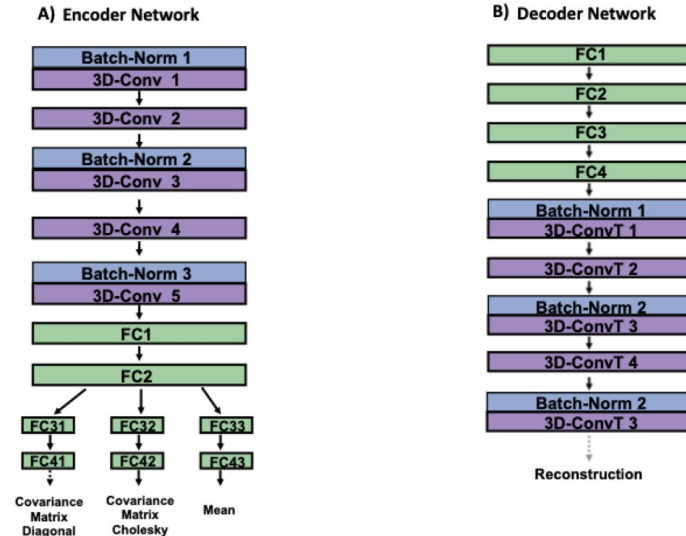


Figure 6: Neural Network Architecture.

# Deep Latent State Space Models for Time-Series Generation



## Общее описание

- Методы, основанные на обыкновенных дифференциальных уравнениях (ОДУ), широко используются для построения порождающих моделей временных рядов. Но есть проблема — вычислительная сложность.
- Предложена модель LS4 — генеративная модель для последовательностей со скрытыми переменными, эволюционирующими в соответствии с пространством состояний ОДУ.
- Показано, что LS4 значительно превосходит предыдущие генеративные модели временных рядов с точки зрения маргинального распределения, классификации и прогнозных оценок на реальных наборах данных, а также способна моделировать стохастические данные.
- Можно сказать, что LS4 — SOTA для латентных порождающих моделей временных рядов.

## Минус

- Работают с одномерными данными

### 3.1. State Space Models (SSM)

A *single-input single-output (SISO)* linear state space model is defined by the following differential equation

$$\begin{aligned} \frac{d}{dt} \mathbf{h}_t &= \mathbf{A} \mathbf{h}_t + \mathbf{B} x_t \\ y_t &= \mathbf{C} \mathbf{h}_t + \mathbf{D} x_t \end{aligned} \quad (1)$$

with scalar *input*  $x_t \in \mathbb{R}$ , *state*  $\mathbf{h}_t \in \mathbb{R}^N$  and scalar *output*  $y_t \in \mathbb{R}$ . The system is fully characterized by the matrices  $\mathbf{A} \in \mathbb{R}^{N \times N}$ ,  $\mathbf{B} \in \mathbb{R}^{N \times 1}$ ,  $\mathbf{C} \in \mathbb{R}^{1 \times N}$ ,  $\mathbf{D} \in \mathbb{R}^{1 \times 1}$ . Let

$$\begin{aligned} \mathbf{h}_{t_{k+1}} &= \bar{\mathbf{A}} \mathbf{h}_{t_k} + \bar{\mathbf{B}} x_{t_k} \\ y_{t_k} &= \mathbf{C} \mathbf{h}_{t_k} + \mathbf{D} x_{t_k} \end{aligned} \quad (2)$$

where  $\bar{\mathbf{A}} = e^{\mathbf{A}\Delta}$ ,  $\bar{\mathbf{B}} = \mathbf{A}^{-1}(e^{\mathbf{A}\Delta} - \mathbf{I})\mathbf{B}$  with the assumption that signals are constant during the sampling interval.

Among many approaches to efficiently computing  $e^{\mathbf{A}\Delta}$ , Gu et al. (2021) use a bilinear transform to estimate  $e^{\mathbf{A}\Delta} \approx (\mathbf{I} - \frac{1}{2}\mathbf{A}\Delta)^{-1}(\mathbf{I} + \frac{1}{2}\mathbf{A}\Delta)$ .

This recurrence equation can be used to iteratively solve for the next hidden state  $\mathbf{h}_{t_{k+1}}$ , allowing the states to be calculated like an RNN or a Neural ODE (Chen et al., 2018;

# The Algonauts Project 2021 Challenge: How the Human Brain Makes Sense of a World in Motion



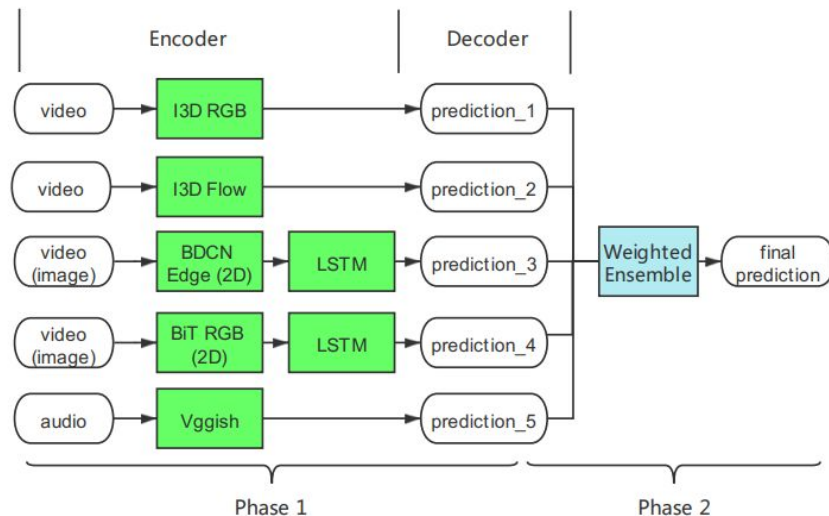
- Соревнование по предсказанию fMRI мозга (1 картинка) по 3 секундному видео. Был представлен датасет (сейчас недоступен, но наверное можно попросить) из 102 видео и fMRI 10 людей.
- Было представлено 2 категории мини и полная. В мини необходимо было предсказывать лишь некоторые интересующие зоны, в полной весь мозг (что является почти нашей задачей за исключением того, что мы должны предсказывать видео, а не картинку)
- На странице соревнования есть таблица с результатами, репортами, а кое-где и кодом участников.
- Есть туллит, включающий в себя визуализацию fMRI и простенький бейзлайн



# Effective Ensemble of Deep Neural Networks Predicts Neural Responses to Naturalistic Videos




Решение победителей соревнования. Используется ансамбль энкодер-декодеров, каждый из которых отвечает за разные области: пространственно-временная информация, движение, контуры, статичные картинки, аудио. Есть гитхаб и реализация, но та же самая проблема с датасетом, что и у всего соревнования.



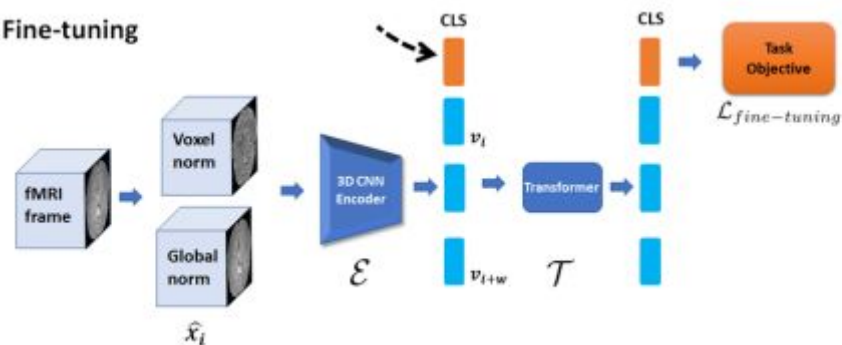
# Self-Supervised Transformers for fMRI representation



Pre-training



Fine-tuning



Трансформер для анализа fMRI: TFF (a Transformer framework for the analysis of functional Magnetic Resonance Imaging)


Уже есть предобученный со всеми весами, возможно использовать его декодер для нашей задачи.


# An Intuitive Tutorial to Gaussian Processes Regression by J. Wang



Регрессия гауссовских процессов.


К сожалению, её работа занимает  $O(N^3)$  по времени и  $O(N^2)$  по памяти, что не подойдет для нашей задачи. Однако, возможно стоит рассмотреть разреженные гауссовские процессы.






## Deep Direct Discriminative Decoders for High-dimensional Time-series Data Analysis

### Bayesian Decoder Models with a Discriminative Observation Process






## Real-Time Point Process Filter for Multidimensional Decoding Problems Using Mixture Models

Высокое время обработки видео и FMRI. Авторы предложили использовать смесь гауссиан для моделирования отклика каждой клетки FMRI, тем самым сократив время вычислений до приемлемого на практике. Для обучения использовался принцип максимизации вариационной нижней оценки ELBO. Однако в статье рассматривались только низкоразмерные данные без пространственной составляющей, что является плохим приближением FMRI.

$$p(X_k|X_{k-1}) \sim N(A_{k-1} X_{k-1} + B_{k-1}, \Sigma_Q)$$



Надеюсь, тебе понравилось, так как мы старались